Санкт-Петербургский политехнический университет Петра Великого Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №3
"Боксплот Тьюки и анализ выбросов"

Работу выполнила:
Ятманова А. В.
Группа:
5030102/30202
Преподаватель:
Баженов А.Н.

Санкт-Петербург
2026

Оглавление

Формулировка задачи 3
Теоретическая часть 3
Реализация 3
Результаты: 4
Нормальное распределение 4
Распределение Коши 4
Распределение Лапласа 5
Распределение Пуассона 5
Распределение равномерное 6
Обсуждение 7
Вывод 7
Приложения 7

Формулировка задачи

Цель:

Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений. Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

Задачи:

1. Сгенерировать выборки объёмом n = 20, 100. Построить боксплот Тьюки.
2. Определить долю выбросов экспериментально: для каждого распределения сгенерировать 1000 выборок заданного объёма, вычислить среднюю долю выбросов.

Теоретическая часть

Используемые распределения

1) Нормальное распределение

$$N(0,1);\ \mathrm{f(x)} = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}\ (1)$$

2) Распределение Коши

$$C(0,1);\ f(x) = \frac{1}{\pi(1+x^2)}\ (2)$$

3) Распределение Лапласа

$$L\left(0, \frac{1}{\sqrt{2}}\right); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}\ (3)$$

4) Распределение Пуассона

$$P(5); f(k) = \frac{10^k e^{-10}}{k!}\ (4)$$

5) Равномерное распределение

$$U\left(-\sqrt{3}, \sqrt{3}\right); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, x \epsilon \left[-\sqrt{3}; \sqrt{3}\right] \\ 0, x \notin \left[-\sqrt{3}; \sqrt{3}\right] \end{cases}\ (5)$$

Расчёт доли аномальных значений

1. Подсчитываем квантили $z_{\frac{1}{4}}$ и $z_{\frac{3}{4}}$
2. Подсчитываем межквартильный размах IQR

$$IQR = z_{\frac{3}{4}} - z_{\frac{1}{4}}$$

3. Подсчитываем границы:

$$\text{Верхняя} = z_{\frac{3}{4}} + 1.5IQR$$

$$\text{Нижняя} = z_{\frac{1}{4}} - 1.5IQR$$

4. Все значения, которые не выходят в эти границы – аномальные значения
5. Считаем их количество и находим долю

Для доли считается выборочное среднее:

$$E(z) = \frac{1}{n}\sum_{i=1}^{n} z_i$$

Реализация

Используемый язык: Python 3.14
Используемая среда разработки: Jupiter Notebook
Используемые библиотеки: numpy, matplotlib, scipy

Описание функций:

tukey_limits(sample) - Функция вычисляет границы, используемые для определения выбросов по правилу Тьюки. Для этого находятся первый и третий квартили выборки, после чего рассчитывается межквартильный размах (IQR). Функция возвращает значения этих границ.

detect_outliers(sample) - Функция определяет выбросы в выборке. Сначала с помощью функции tukey_limits вычисляются границы допустимых значений, после чего выбираются элементы выборки, которые находятся за пределами этих границ. Результатом работы функции является массив значений, являющихся выбросами.

outlier_fraction(sample) - Функция вычисляет долю выбросов в одной выборке. Для этого определяется количество выбросов с помощью функции detect_outliers, после чего вычисляется отношение числа выбросов к общему количеству элементов в выборке.

average_outlier_share(generator, n, repeats) - Функция используется для оценки средней доли выбросов. Она многократно генерирует выборки заданного размера с использованием переданной функции-генератора распределения. Для каждой выборки вычисляется доля выбросов, после чего возвращается среднее значение этой доли по всем экспериментам.

draw_boxplots(samples, dist_name, sizes) - Функция строит боксплоты Тьюки для заданных выборок. Для каждого размера выборки создаётся отдельный график, на котором отображается распределение значений, медиана, квартили и возможные выбросы. Графики используются для визуального анализа структуры данных.

run_lab() - Функция объединяет все этапы работы программы и запускает проведение эксперимента.

Результаты:

Нормальное распределение

Боксплоты

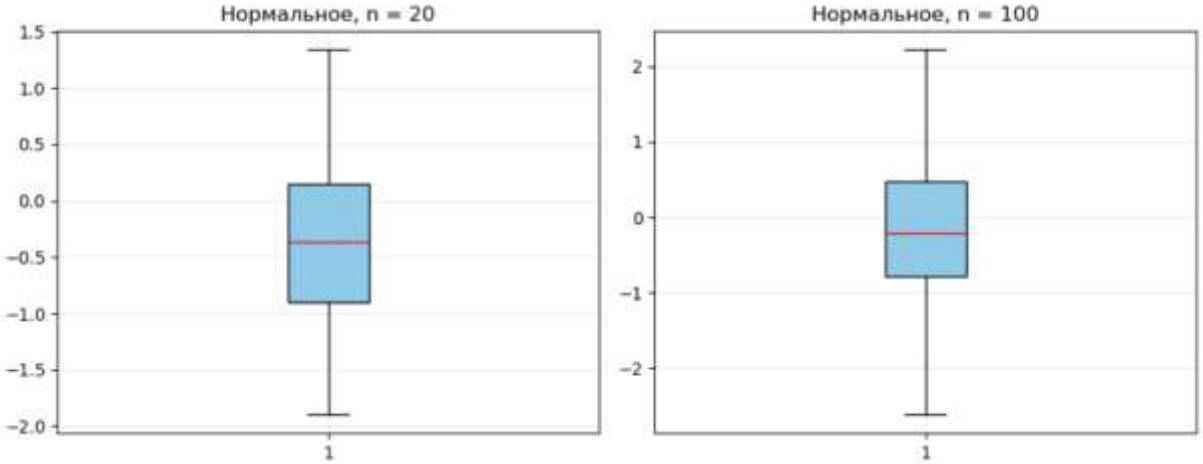

Рис 1. Боксплоты для нормального распределения

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.02
100	0.01

Рис 2. Доля аномальных значений для нормального распределения

Распределение Коши

Боксплоты

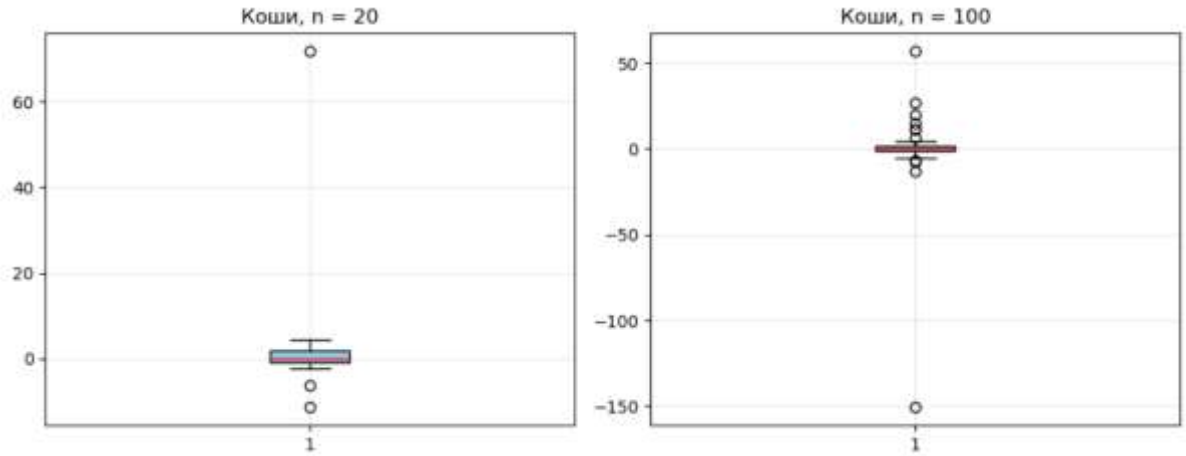

Рис 3. Боксплоты для распределения Коши

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.15
100	0.15

Рис 4. Доля аномальных значений для распределения Коши

Распределение Лапласа

Боксплоты

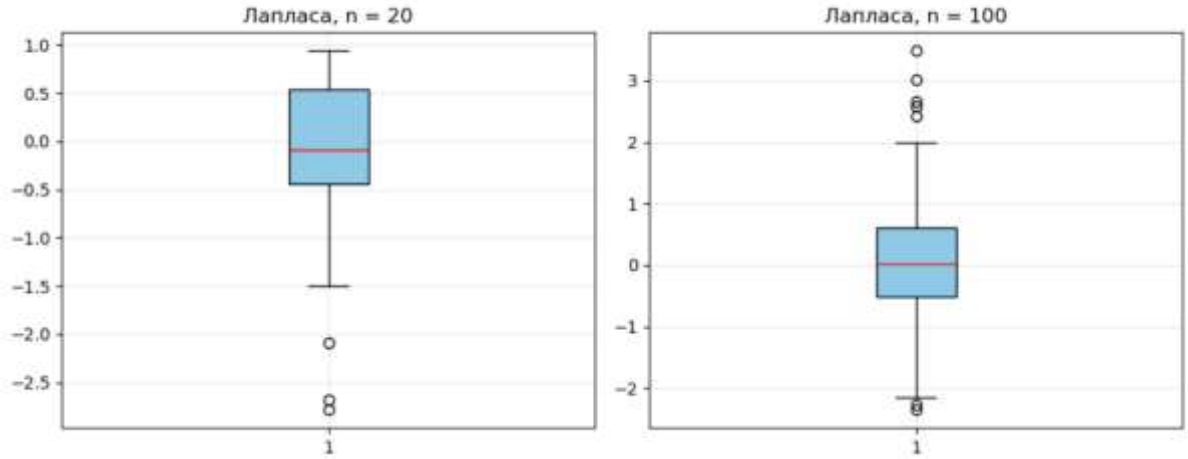

Рис 5. Боксплоты для распределения Лапласа

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.07
100	0.06

Рис 6. Доля аномальных значений для распределения Лапласа

Распределение Пуассона

Боксплоты

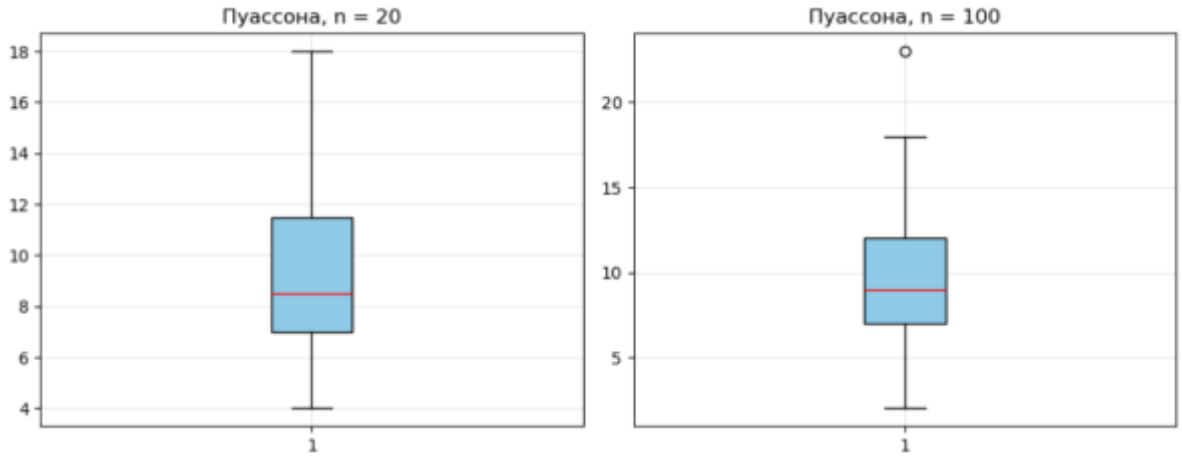

Рис 7. Боксплоты для распределения Пуассона

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.025
100	0.01

Рис 8. Доля аномальных значений для распределения Пуассона

Распределение равномерное

Боксплоты

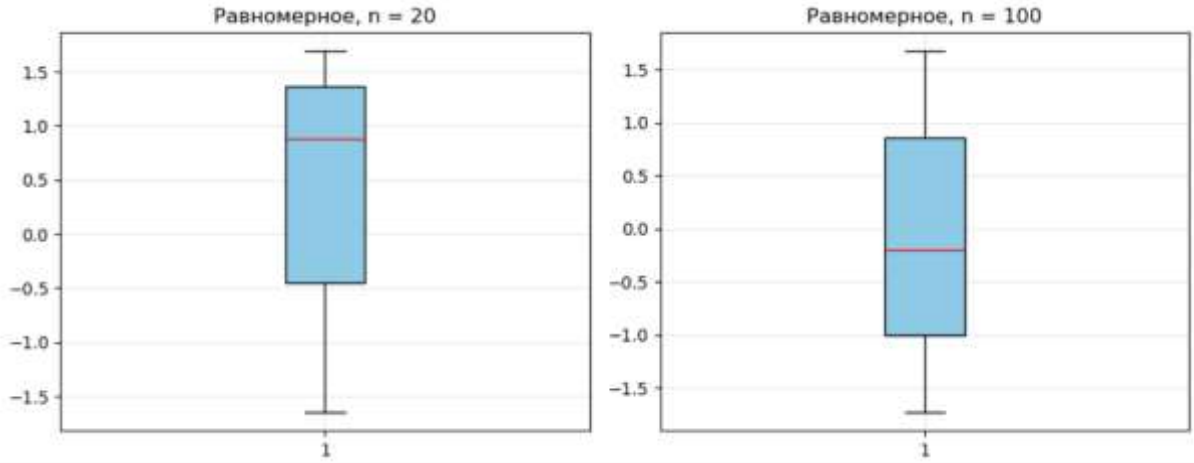

Рис 9. Боксплоты для равномерного распределения

Доля аномальных значений

Размер выборки	Средняя доля выбросов
20	0.03
100	0.00

Рис 10. Доля аномальных значений для равномерного распределения

Обсуждение

Боксплот Тьюки — это графический способ компактно представить основные характеристики выборки и выявить возможные выбросы. Центральная линия внутри прямоугольника показывает медиану выборки. Границы прямоугольника соответствуют первому и третьему квартилям, то есть значениям, между которыми находится центральные 50 % наблюдений. Длина прямоугольника отражает межквартильный размах и характеризует разброс основной части данных. «Усики» показывают значения, которые лежат за пределами квартилей, но всё ещё не считаются выбросами. Точки, расположенные за пределами усов, обозначают выбросы — значения, выходящие за границы, определяемые правилом Тьюки.

Анализ полученных результатов позволяет сделать следующие выводы:

1. Нормальное распределение. Доля выбросов невелика и обычно не превышает нескольких процентов. При увеличении размера выборки результаты становятся более стабильными.
2. Распределение Коши. Наблюдается наибольшая доля выбросов среди всех рассмотренных распределений. При увеличении размера выборки эта доля практически не уменьшается, что связано с тяжёлыми хвостами распределения и высокой вероятностью появления экстремальных значений.
3. Распределение Лапласа. Доля выбросов выше, чем у нормального и пуассоновского распределений, что объясняется более тяжёлыми хвостами распределения.
4. Распределение Пуассона. Доля выбросов также относительно мала и близка к значениям, наблюдаемым для нормального распределения.
5. Равномерное распределение. Практически не содержит выбросов при обоих размерах выборки. Это связано с тем, что значения равномерно распределены в ограниченном интервале и не имеют длинных хвостов.

Вывод

По результатам лабораторной работы можно сделать следующие выводы.

Боксплот Тьюки является удобным и наглядным способом представления данных. Он позволяет отобразить основные характеристики выборки (медиану, квартили, межквартильный размах) и выявить возможные выбросы, что делает его полезным инструментом для первичного анализа данных.

Анализ доли выбросов показал, что она зависит от типа распределения. Для равномерного распределения выбросы практически отсутствуют из-за ограниченности диапазона значений. Для нормального и пуассоновского распределений доля выбросов невелика и уменьшается с увеличением размера выборки. Распределение Лапласа имеет более высокую долю выбросов, а для распределения Коши она является наибольшей и практически не уменьшается при росте объёма выборки.

Таким образом, результаты подтверждают зависимость доли выбросов от формы распределения и показывают эффективность боксплота Тьюки для выявления аномальных значений.

Приложения

Репозиторий GitHub: https://github.com/anyyaa/mathstat