

Санкт-Петербургский политехнический университет Петра
Великого Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №5
"Корреляционный анализ и эллипсы рассеивания"

Работу выполнила:

Ятманова А. В.

Группа:

5030102/30202

Преподаватель:

Баженов А.Н.

Санкт-Петербург
2026

Оглавление

Формулировка задачи	2
Теоретическая часть.....	3
Реализация	3
Результаты:	4
Обсуждение	8
Вывод	9
Приложения	9

Формулировка задачи

Цели:

Сравнить исходное значение коэффициента корреляции с вычисленными на практике.
Изучить способы визуализации ковариационных данных.

Задачи:

- Сгенерировать двумерные выборки из двумерного нормального распределения и смеси распределений.
- Для каждой выборки вычислить коэффициенты корреляции Пирсона, Спирмена и квадрантный.
- Повторить вычисления 1000 раз, найти средние значения и дисперсии для каждого коэффициента.
- Построить эллипсы равновероятности для визуализации.

Теоретическая часть

Используемые распределения

- 1) Двумерное нормальное распределение

$$N(0,0,1,1,\rho) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right)$$

- 2) Смесь распределений

$$0.9 \cdot N(0,0,1,1,0.9) + 0.1 \cdot N(0,0,10,10,-0.9)$$

Расчет коэффициентов корреляции

Коэффициент корреляции Пирсона

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Коэффициент ранговой корреляции Спирмена

$$r_s = \frac{\sum_{i=1}^n (u_i - \bar{u})(v_i - \bar{v})}{\sqrt{\sum_{i=1}^n (u_i - \bar{u})^2 \sum_{i=1}^n (v_i - \bar{v})^2}}$$

где u_i и v_i — ранги i -ых элементов выборок, а $\bar{u}$ и $\bar{v}$ — средние значения рангов.

Квадрантный коэффициент корреляции

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n},$$

где n_i — количество точек в i -ой квадранте относительно медиан.

Расчет коэффициента корреляции для смеси распределений

Дисперсия симметрична для x и y , поэтому найдём общую:

$$D = 0.9^2 \cdot D_1 + 0.1^2 \cdot D_2 = 0.91$$

Коэффициент ковариации:

$$\text{cov}(X, Y) = 0.9^2 \cdot 0.9 + 0.1^2 \cdot (-0.9) \cdot \sqrt{10} \cdot \sqrt{10} = 0.639$$

Коэффициент корреляции:

$$r_{xy} = \frac{\text{cov}(X, Y)}{\sqrt{D_X} \sqrt{D_Y}} = \frac{0.639}{\sqrt{0.91} \cdot \sqrt{0.91}} \approx 0.702$$

Реализация

Используемый язык: Python 3.14

Используемая среда разработки: Jupiter Notebook

Используемые библиотеки: numpy, matplotlib, scipy

Описание функций

quadrant_corr

Вычисляет квадрантный коэффициент корреляции на основе медиан выборок.

Данные центрируются относительно медиан, после чего подсчитывается количество точек в каждом квадранте.

Коэффициент определяется как разность «согласованных» и «несогласованных» квадрантов, делённая на объём выборки.

generate_mixture

Генерирует выборку из смеси двух двумерных нормальных распределений.

С вероятностью 0.9 выбираются точки из распределения с высокой положительной корреляцией, с вероятностью 0.1 — с отрицательной корреляцией и большим разбросом.

Используется случайная маска для формирования итоговой смешанной выборки.

draw_ellipse

Строит эллипс рассеивания по выборочным данным.

Эллипс определяется через ковариационную матрицу: собственные значения задают длины осей, собственные векторы — ориентацию.

Центр эллипса совпадает с выборочным средним значением.

plot_data_block

Визуализирует набор выборок в виде диаграмм рассеивания.

Для каждой выборки строится облако точек и соответствующий эллипс рассеивания.

Графики оформляются с сеткой, осями и заголовками для наглядного сравнения.

print_summary

Выводит статистические характеристики коэффициентов корреляции.

Для каждой комбинации параметров вычисляются среднее значение (M) и дисперсия (D).

Результаты отображаются в табличном виде для последующего анализа.

run_experiment

Организует полный вычислительный эксперимент.

Генерирует выборки, многократно вычисляет коэффициенты корреляции и сохраняет результаты.

Формирует итоговые таблицы и строит графики для анализа нормального и смешанного распределений.

Результаты:

Средние значения коэффициентов корреляции (1000 экспериментов):

Распределение	n = 20		n = 60		n = 100	
	r	D	r	D	r	D
Нормальное $\rho = 0$	0.004	0.051	-0.003	0.019	-0.002	0.010
Нормальное $\rho = 0.5$	0.494	0.029	0.498	0.009	0.500	0.006
Нормальное $\rho = 0.9$	0.896	0.002	0.898	0.001	0.898	0.0003
Смесь	0.193	0.271	0.058	0.114	0.011	0.070

Таблица 1 – Коэффициент Пирсона r для разных n

Распределение	n = 20		n = 60		n = 100	
	r_s	D	r_s	D	r_s	D

Нормальное $\rho = 0$	0.002	0.051	-0.003	0.018	-0.003	0.010
Нормальное $\rho = 0.5$	0.464	0.032	0.476	0.010	0.481	0.007
Нормальное $\rho = 0.9$	0.866	0.005	0.883	0.001	0.885	0.001
Смесь	0.530	0.062	0.540	0.021	0.535	0.013

Таблица 2 – Коэффициент Спирмена r_s для разных n

Распределение	n = 20		n = 60		n = 100	
	r_Q	D	r_Q	D	r_Q	D
Нормальное $\rho = 0$	0.003	0.053	-0.001	0.018	-0.001	0.011
Нормальное $\rho = 0.5$	0.326	0.040	0.330	0.014	0.336	0.009
Нормальное $\rho = 0.9$	0.693	0.030	0.706	0.008	0.707	0.005
Смесь	0.538	0.039	0.558	0.011	0.561	D=0.007

Таблица 3 – Квадрантный коэффициент r_Q для разных n




Рисунок 1: Двумерное нормальное распределение для выборки $n = 20$




Рисунок 2: Двумерное нормальное распределение для выборки $n = 60$




Рисунок 3: Двумерное нормальное распределение для выборки $n = 100$

Смешанное, $n = 20$




Рисунок 4: Эллипс рассеяния для смеси распределений при размере выборки 20




Рисунок 5: Эллипс рассеяния для смеси распределений при размере выборки 60




Рисунок 6: Эллипс рассеяния для смеси распределений при размере выборки 20

Обсуждение

В ходе эксперимента были исследованы три коэффициента корреляции: Пирсона, Спирмена и квадратный для двумерного нормального и смешанного распределений.

1. Влияние объёма выборки

Для всех коэффициентов наблюдается уменьшение дисперсии при увеличении объёма выборки (от $n = 20$ к $n = 100$). Это означает, что оценки становятся более стабильными и сходятся к своим средним значениям.

2. Двумерное нормальное распределение

Коэффициент Пирсона показал наилучшее совпадение с заданным значением ρ . Например, при $\rho = 0.9$ его среднее значение достигает 0.898 при $n = 100$.

Коэффициент Спирмена даёт немного заниженные значения, но остаётся близким к истинному.

Квадратный коэффициент существенно недооценивает корреляцию (например, 0.707 при $\rho = 0.9$), что связано с использованием только знаков отклонений.

3. Смешанное распределение

Добавление 10% точек с большой дисперсией и отрицательной корреляцией сильно влияет на результаты:

коэффициент Пирсона резко уменьшается (до ~ 0.01 при $n = 100$) и имеет большую дисперсию следовательно он чувствителен к выбросам;

коэффициенты Спирмена и квадрантный сохраняют значения на уровне ~ 0.53 – 0.56 поэтому они более устойчивы.

4. Эллипсы рассеяния

Для нормального распределения с ростом ρ эллипс вытягивается вдоль прямой $y=x$ и становится более узким, что отражает усиление линейной зависимости.

Для смеси распределений эллипсы становятся менее выраженными и более «размытыми», так как выбросы искажают структуру данных.

Вывод

По результатам работы можно сделать следующие выводы:

- С увеличением объёма выборки дисперсия всех коэффициентов уменьшается, что подтверждает их состоятельность и сходямость.
- Для двумерного нормального распределения наиболее точным является коэффициент Пирсона, так как он лучше всего восстанавливает заданное значение корреляции.
- Коэффициент Спирмена показывает близкие к истинным значения и может рассматриваться как компромисс между точностью и устойчивостью.
- Квадрантный коэффициент является наименее точным, но более устойчивым к выбросам.
- При наличии выбросов (смесь распределений) коэффициент Пирсона теряет информативность, тогда как Спирмен и квадрантный остаются устойчивыми и дают более адекватную оценку зависимости.
- Визуальный анализ подтверждает результаты: при увеличении корреляции эллипсы вытягиваются, а при наличии выбросов их форма и ориентация искажаются.

Приложения

Репозиторий GitHub: <https://github.com/anyyaa/mathstat>